

Resultados y elección del modelo final

Tabla X. Candidatos a modelo final.

Modelo	MAE val	MAE test	Captura (%)	Pico ± 1 h (%)	Mejora frente a persistencia (%)
Ensemble seleccionado (modelo final)	11,73	11,72	92,6	76,4	29,9
Ensemble seleccionado con ancla semanal (descartado)	11,83	12,17	92,2	78,3	27,2
Media simple de 8 familias	12,52	12,03	90,5	77,4	28,0
Media simple de 12 familias (regla anterior)	12,63	11,88	92,9	78,3	28,9
Red densa	12,94	13,29	88,5	74,7	20,5
LightGBM global	13,06	14,25	90,5	75,0	14,8
GRU	14,13	13,19	89,6	77,0	21,1
Persistencia (precio de D)	19,95	16,72	86,1	67,5	—

Nota: MAE en €/MWh; validación 2025 (365 días), test enero-julio de 2026 (212 días). Captura del spread, pico y mejora (reducción relativa del MAE), en test. Modelos individuales: media de 3 semillas; medias simples: mejor semilla de cada familia.

Elección. Miembros y pesos se fijaron solo con validación, mediante selección voraz hacia delante con reemplazo en 30 pasos: LightGBM global (11/30), red densa (10/30), LSTM (3/30), seq2seq de precio absoluto (3/30), GRU (2/30) y seq2seq residual (1/30). Por eso el MAE de validación de los ensembles seleccionados es optimista y la medida honesta es el test.

Test. Confirma el primer puesto. El contraste diario (bloques móviles de siete días, 5000 réplicas; IC al 95 % de la diferencia rival menos ensemble) le da ventaja clara sobre la persistencia (+5,00 [3,93; 6,34]), LightGBM global (+2,44 [1,49; 3,46]) y GRU (+1,16 [0,66; 1,82]), con la semilla miembro (14,16 y 12,89), y la variante con ancla semanal (+0,44 [0,14; 0,78]). Frente a las medias simples no es significativa: +0,16 [−0,28; 0,76] con 12 familias y +0,31 [−0,05; 0,77] con 8.

Aportación. Se concentra en LightGBM global y la red densa: sin cada uno, el MAE de test sube a 12,70 y 12,18; los otros cuatro apenas cambian el test.

Limitaciones. La selección se prefiere por el criterio de validación, pero el método no se eligió a ciegas respecto al test: la regla anterior, media de las familias que batían a la persistencia en validación, incluía Ridge y SARIMAX, que no la baten en test (19,18 y 21,45 frente a 16,72), y se substituyó tras verlo. El test no es del todo independiente para comparar selección y media simple.

Un menor MAE no garantiza mejor orden horario: la media de 12 familias acierta más el pico (78,3 % frente a 76,4 %), y el seq2seq de precio absoluto y Ridge llegan al 81,4 % y 81,6 %, sin contraste de incertidumbre.

Las previsiones de REE para D+1 se cargaron ya revisadas en validación y test, por lo que el MAE de test y la mejora del 29,9 % pueden ser optimistas frente a producción, que solo dispone de la previsión de las 11:00 de D. Queda pendiente medirlo reentrenando sin esas variables.