

Modelos de predicción del precio D+1

Qué se entrenó, por qué, con qué método y con qué precisión. Responde al punto iii de la guía del TFM —técnicas de modelización justificadas, nivel de precisión, bondades y debilidades— y a sus apartados a y b: qué aporta el trabajo frente a un AutoML y frente a un trabajo de fin de módulo.

Resultados del 30/08/2026 Matriz núcleo 8 familias × 3 semillas = 24 entrenamientos

Test abierto una vez

Documento de trabajo. El planteamiento, la tabla y el último apartado están pensados para la memoria; si falta espacio, las fichas pueden resumirse o pasar al anexo.


PLANTEAMIENTO

Un problema y unas reglas comunes a todos los modelos

Qué se predice	Las 24 horas de precio del mercado diario del día siguiente (D+1), de una sola vez, con lo publicado a las 11:00 del día D, antes de que el mercado cierre a las 12:00. Es una predicción multisalida directa: un operador de batería necesita el perfil completo del día para decidir cuándo carga y cuándo descarga, así que no se encadenan predicciones hora a hora realimentando la salida.
Con qué información	Tres entradas, con la hora de publicación de cada columna medida contra las tablas de origen: una ventana de 168 horas (7 días) con 51 canales —precio, programas y series observadas hasta D-1—; 22 variables por cada hora de D+1 —previsiones de demanda y renovables, capacidad de interconexión, meteorología prevista, precio de D en España y países vecinos, y la hora—; y 29 variables constantes del día —capacidades, calendario, gas y CO ₂ —.
Partición temporal	Entrenamiento 2020–2024 (1.812 días), validación 2025 (365 días) y test del 1 de enero al 31 de julio de 2026 (212 días). Los escaladores se ajustan solo con entrenamiento; la validación decide la parada temprana y la selección; el test se abre una vez, al final.
Objetivo	Salvo en una familia, los modelos no predicen el precio sino su diferencia con el del día D, hora a hora y estandarizada. Así parten de una estimación razonable —la persistencia— y no tienen que aprender el nivel del precio: el entrenamiento incluye la crisis del gas de 2022 y el nivel de test queda medio sigma por debajo de su media.
Entrenamiento	Mismas condiciones para todas las redes: pérdida de Huber ($\delta = 1$), que limita el peso de los picos extremos sin ignorarlos; Adam con tasa 0,001, reducida a la mitad tras 5 épocas sin mejora en validación; parada temprana a las 12 épocas restaurando los mejores pesos (máximo 80, lotes de 64); y dropout de 0,3 (0,2 en el Denso). Tres semillas por familia —42, 43 y 44—: se informa media ± desviación, nunca la mejor ejecución.

Cómo se mide

MAE en €/MWh sobre las 24 horas; mejora frente a la persistencia; **captura del diferencial**, la parte del arbitraje perfecto del día que se obtiene cargando en la hora más barata predicha y descargando en la más cara predicha; y acierto de la hora pico con un margen de ± 1 h.



Esqueleto común de las seis familias recurrentes, en el orden en que circula la información. Cada familia cambia una sola pieza, de modo que cualquier diferencia de resultado tiene una causa identificable.

PRECISIÓN

Qué precisión alcanza cada técnica


Cifras de la ejecución final de `06_modelos_finales.ipynb`, media de tres semillas. El test —enero a julio de 2026— no intervino en ninguna decisión: la parada temprana y la selección del ensemble usan solo validación.

Cuánto mejora cada modelo a la persistencia

Reducción del MAE frente a repetir el precio del día anterior; más a la derecha, mejor. Se compara en porcentaje porque los periodos no son igual de difíciles: la persistencia comete 19,95 €/MWh en validación y 16,71 en test.

● Validación 2025

● Test 2026



MODELO	QUÉ CAMBIA	PARÁMETROS	MAE VALIDACIÓN 2025		MAE TEST 2026	MEJORA SOBRE PERSISTENCIA		CAPTURA	HORA PICO ±1 H
Ensemble	media de las ocho familias	8 modelos	12,20		12,13	27,5 %		92,3 %	80,2 %
GRU	la celda	196.129	13,59 ± 0,18		12,86 ± 0,26	23,1 %		90,0 %	77,4 %
Seq2Seq	referencia	259.681	13,85 ± 0,13		12,91 ± 0,10	22,8 %		89,7 %	73,3 %
Conv1D + LSTM	convolución de entrada	286.305	14,16 ± 0,27		13,40 ± 0,34	19,8 %		89,8 %	77,0 %
SimpleRNN	la celda, sin puertas	34.689	14,62 ± 0,19		13,81 ± 0,65	17,4 %		89,6 %	73,9 %
Boosting por hora	el paradigma: árboles	10.509–11.320 árboles	13,29 ± 0,03		13,85 ± 0,10	17,1 %		88,6 %	77,5 %
Denso	sin recurrencia	566.040	12,79 ± 0,10		15,39 ± 0,81	7,9 %		89,7 %	76,6 %
Seq2Seq absoluto	el objetivo	259.681	15,26 ± 0,33		15,41 ± 0,64	7,8 %		93,0 %	84,6 %
LSTM directa	el decodificador	322.712	13,46 ± 0,29		16,00 ± 0,26	4,3 %		89,1 %	73,9 %
Persistencia	sin modelo	–	19,95		16,71	–		86,6 %	67,9 %

Media ± desviación de tres semillas, MAE en €/MWh, ordenado por MAE de test. La mejora, la captura y la hora pico son de test. En negrita, el mejor valor de cada columna.

Qué dicen las cifras

GRU y Seq2Seq empatan.

12,86 frente a 12,91 €/MWh: 0,05 de diferencia, por debajo de la desviación entre semillas de cualquiera de los dos. Con tres semillas no se puede afirmar que una celda sea mejor que la otra.

Precisión y dinero eligen modelos distintos.

El Seq2Seq absoluto es penúltimo en MAE y primero en captura (93,0 %) y en acierto de la hora pico (84,6 %). En los 24 entrenamientos, menos error no implica más captura: la correlación entre ambas métricas es de +0,20.

El mejor en validación no es el mejor en test.

El Denso y la LSTM directa son primero y tercero en validación y acaban sexto y último en test. El orden de validación no anticipa el de test (correlación de rangos de –0,14). Las dos comparten un rasgo: reciben las previsiones de las 24 horas aplanadas en una capa densa, sin compartir pesos entre horas.

El ensemble gana en error y queda segundo en captura.

12,13 €/MWh, un 5,7 % menos que la GRU y un 27,5 % menos que la persistencia, con una captura del 92,3 % frente al 86,6 % de repetir el día anterior.

Qué se entrenó, por qué y con qué método

En cada ficha, el MAE en €/MWh es la media $\pm$ desviación de tres semillas; la mejora, la captura y la hora pico son de test.

REFERENCIA

SIN MODELO

Persistencia

naive

VALIDACIÓN	19,95
TEST	16,71
CAPTURA	86,6 %
HORA PICO	67,9 %

POR QUÉ

Fija el listón. Repetir mañana el precio de hoy, hora a hora, es lo que haría un operador sin modelo, así que cualquier técnica tiene que batirla para justificar su coste.

BONDADES

Coste nulo, imposible de sobreajustar y más exigente de lo que parece: captura el 86,6 % del arbitraje, porque la forma del día —valle solar, pico al anochecer— se repite de un día para otro.

CÓMO

Sin entrenamiento: cada hora de D+1 recibe el precio casado de esa misma hora en D, que se publica el día anterior. Es también la base sobre la que las demás familias predicen el residuo.

DEBILIDADES

No anticipa nada: falla justo cuando cambian el viento, la solar o el gas, que es cuando más importa. La variante semanal, repetir el mismo día de la semana anterior, es aún peor: 26,4 €/MWh en test durante la exploración.

FAMILIAS RECURRENTES · UNA PIEZA CAMBIADA CADA VEZ

REFERENCIA ARQUITECTÓNICA

Seq2Seq

seq2seq

VALIDACIÓN	13,85 $\pm$ 0,13
TEST	12,91 $\pm$ 0,10
MEJORA	22,8 %
CAPTURA	89,7 %
HORA PICO	73,3 %
TAMAÑO	259.681 parámetros

POR QUÉ

Reproduce la estructura del problema: separa el pasado observado del día que se predice y hace que las previsiones de cada hora entren en esa hora. Es el codificador-decodificador del módulo de redes recurrentes, adaptado a una salida directa de 24 valores.

BONDADES

Segundo en test, a 0,05 €/MWh de la GRU, y la menor desviación entre semillas en test de todas las redes (0,10). Es la referencia contra la que se mide cada cambio.

CÓMO

Codificador LSTM bidireccional de 96 unidades sobre las 168 horas. Su resumen se une a una proyección densa de los estáticos, se repite 24 veces junto a las previsiones de cada hora y un decodificador LSTM de 96 unidades recorre el día. El decodificador no es bidireccional: miraría horas posteriores para predecir la actual.

DEBILIDADES

Es la familia que peor sitúa la hora pico (73,3 %), y pesa un tercio más que la GRU sin mejorarla.

CAMBIA LA CELDA

GRU

gru

VALIDACIÓN	13,59 ± 0,18
TEST	12,86 ± 0,26
MEJORA	23,1 %
CAPTURA	90,0 %
HORA PICO	77,4 %
TAMAÑO	196.129 parámetros

POR QUÉ

Mide si la celda LSTM compensa su coste. La GRU fusiona puertas y tiene tres cuartas partes de sus parámetros; con 1.812 días de entrenamiento, menos parámetros pueden generalizar mejor.

BONDADES

Mejor modelo individual en test con un 25 % menos de parámetros que el Seq2Seq, y acierta la hora pico más a menudo (77,4 % frente a 73,3 %). Conserva buena parte de su mejora al pasar de validación a test: del 31,9 % al 23,1 %.

CÓMO

El mismo codificador-decodificador con celdas GRU de 96 unidades en ambos lados. No cambia nada más.

DEBILIDADES

Su ventaja sobre el Seq2Seq está dentro del ruido entre semillas. Y en validación es solo cuarta: un criterio que eligiera por validación la habría descartado.

CAMBIA LA CELDA · CONTROL DE CAPACIDAD

SimpleRNN

simplernn

VALIDACIÓN	14,62 ± 0,19
TEST	13,81 ± 0,65
MEJORA	17,4 %
CAPTURA	89,6 %
HORA PICO	73,9 %
TAMAÑO	34.689 parámetros

POR QUÉ

Comprueba si hace falta capacidad. Es la celda recurrente elemental, sin puertas y con 64 unidades: entre 5,7 y 9,3 veces más pequeña que las demás recurrentes. Si igualara a las grandes, el límite estaría en los datos y no en el modelo.

BONDADES

Con el 13 % de los parámetros del Seq2Seq mejora a la persistencia un 17,4 %, iguala en test al boosting (13,81 frente a 13,85) y supera al Denso, al Seq2Seq absoluto y a la LSTM directa. Es la más ligera de las recurrentes.

CÓMO

El mismo esqueleto con celdas SimpleRNN de 64 unidades en el codificador y en el decodificador.

DEBILIDADES

Sin puertas, el gradiente se diluye a lo largo de 168 pasos y la memoria es corta: 0,95 €/MWh más de error que la GRU. Además es inestable: sus tres ejecuciones van de 13,06 a 14,22 €/MWh en test.

CAMBIA EL DECODIFICADOR

LSTM directa

lstm

VALIDACIÓN	13,46 ± 0,29
TEST	16,00 ± 0,26
MEJORA	4,3 %
CAPTURA	89,1 %
HORA PICO	73,9 %
TAMAÑO	322.712 parámetros

POR QUÉ

Mide cuánto aporta recorrer el día hora a hora. En lugar de un decodificador recurrente, proyecta las 24 salidas de una vez, que es la formulación multisalida más directa.

BONDADES

Arquitectura sencilla y tercera en validación: sobre el papel, competitiva.

CÓMO

El mismo codificador LSTM bidireccional y la misma proyección de estáticos. El contexto se une a las 24 × 22 previsiones aplanadas y pasa por una capa densa de 256 unidades con dropout y otra de 24 salidas.

DEBILIDADES

Es la que más se degrada fuera de muestra: su mejora sobre la persistencia cae del 32,5 % en validación al 4,3 % en test, y queda última. Al aplanar las previsiones, cada hora tiene sus propios pesos; la explicación más probable es que aprenda pautas horarias del periodo de entrenamiento que no se repiten en 2026.

AÑADE UNA CONVOLUCIÓN

Conv1D + LSTM

conv1d_lstm

VALIDACIÓN	14,16 ± 0,27
TEST	13,40 ± 0,34
MEJORA	19,8 %
CAPTURA	89,8 %
HORA PICO	77,0 %
TAMAÑO	286.305 parámetros

POR QUÉ

Prueba si extraer patrones locales antes de la recurrencia facilita el aprendizaje. La convolución con paso 4 reduce las 168 horas a 42 pasos: una secuencia cuatro veces más corta que recordar.

BONDADES

Tercera en test, y sitúa la hora pico casi tan bien como la GRU (77,0 % frente a 77,4 %).

CÓMO

Convolución causal de 64 filtros, con núcleo de 5 horas y paso 4, y normalización por lotes, delante del mismo codificador-decodificador LSTM.

DEBILIDADES

No mejora al Seq2Seq del que parte (13,40 frente a 12,91 €/MWh): en este problema, comprimir la ventana pierde más de lo que ahorra. Añade además un bloque más que ajustar.

CAMBIA EL OBJETIVO

Seq2Seq absoluto

seq2seq_absoluto

VALIDACIÓN	15,26 ± 0,33
TEST	15,41 ± 0,64
MEJORA	7,8 %
CAPTURA	93,0 %
HORA PICO	84,6 %
TAMAÑO	259.681 parámetros

POR QUÉ

Aísla el efecto del objetivo residual: la misma arquitectura que el Seq2Seq, pero prediciendo el precio directamente en lugar de su diferencia con el día anterior.

BONDADES

Construye la curva desde cero, sin heredar la forma de la víspera, y por eso localiza mejor que ningún otro el valle y el pico: mejor captura (93,0 %) y mejor acierto de la hora pico (84,6 %). Es el más útil para decidir cuándo cargar.

CÓMO

Codificador-decodificador LSTM idéntico, entrenado sobre el precio estandarizado con la media y la desviación de entrenamiento.

DEBILIDADES

Le cuesta el nivel: 2,50 €/MWh más de error que la misma red con objetivo residual, porque tira hacia la media que vio en entrenamiento y el nivel de test está medio sigma por debajo. Es también de los más sensibles a la semilla (desviación de 0,64).

SOBRE UNA VISTA PLANA DE 836 COLUMNAS

QUITA LA RECURRENCIA

Denso

denso

VALIDACIÓN	12,79 ± 0,10
TEST	15,39 ± 0,81
MEJORA	7,9 %
CAPTURA	89,7 %
HORA PICO	76,6 %
TAMAÑO	566.040 parámetros

POR QUÉ

Es el control de la recurrencia: si una red sin noción de orden igualara a las recurrentes, la estructura secuencial no aportaría nada.

BONDADES

El mejor modelo individual en validación. Resumir la semana en estadísticos reduce las 8.568 columnas de la ventana completa a 836 y lo hace muy rápido de entrenar.

CÓMO

Perceptrón multicapa (512 → 256 → 24, dropout de 0,2) sobre una vista plana de 836 columnas: el precio de las 24 horas de D; la media, el mínimo y el máximo de cada canal en la semana; su media y su tendencia en el día D; las previsiones de las 24 horas aplanadas, y los estáticos.

DEBILIDADES

El mayor desplome de validación a test (+2,6 €/MWh) y la mayor dispersión: sus semillas van de 14,49 a 16,07 €/MWh. Es el modelo que habría escogido una selección automática por validación.

CAMBIA EL PARADIGMA

Boosting por hora

boosting

VALIDACIÓN	13,29 ± 0,03
TEST	13,85 ± 0,10
MEJORA	17,1 %
CAPTURA	88,6 %
HORA PICO	77,5 %
TAMAÑO	10.509–11.320 árboles

POR QUÉ

Es el contraste no neuronal. El gradient boosting sobre árboles es la referencia en datos tabulares: robusto, sin supuestos sobre la forma de las relaciones y poco sensible a la escala. Si las redes no lo batían, no se justifican.

BONDADES

Segundo en validación y el más estable entre semillas en ese periodo (desviación de 0,03). Tras el Seq2Seq absoluto, es el que mejor sitúa la hora pico (77,5 %).

CÓMO

24 modelos LightGBM independientes, uno por hora, sobre la misma vista plana y el objetivo residual: hasta 800 árboles con tasa 0,03 y 31 hojas, pérdida Huber, submuestreo del 80 % de filas y columnas, y parada a los 50 árboles sin mejora en validación. Se guardan en el formato nativo de LightGBM, legible sin depender de la versión de Python.

DEBILIDADES

Cada hora se predice sin información de las demás, y nada obliga a que la curva del día sea coherente. En test pierde la mitad de su ventaja: del 33,4 % al 17,1 %. Y sin submuestreo es determinista: las tres semillas daban el mismo modelo y una desviación de 0,000 que parecía estabilidad y era un artefacto.

COMBINACIÓN

UN REPRESENTANTE POR FAMILIA

Ensemble

ensemble

VALIDACIÓN	12,20
TEST	12,13
MEJORA	27,5 %
CAPTURA	92,3 %
HORA PICO	80,2 %
TAMAÑO	8 modelos

POR QUÉ

Arquitecturas distintas no se equivocan igual, y al promediarlas los errores se compensan en parte. Se toma un representante por familia y no todas las variantes: varias versiones del mismo esqueleto le darían a esa arquitectura la mayoría del voto.

BONDADES

Mejor MAE en validación y en test, y segundo en captura y en hora pico. No depende de acertar qué familia generalizará: absorbe la caída del Denso y de la LSTM directa.

CÓMO

Media simple de las predicciones horarias de las ocho familias, cada una con su semilla de menor MAE en validación. Solo entran familias que batían a la persistencia en validación; el test no interviene.

DEBILIDADES

Son ocho modelos que mantener y ejecutar cada día, y el conjunto es menos interpretable que cualquiera de ellos por separado. En captura sigue por debajo del Seq2Seq absoluto (92,3 % frente a 93,0 %).

EXPLORACIÓN

Lo que se probó y no llegó a los modelos finales

Más de cuarenta entrenamientos previos en los cuadernos de redes recurrentes. Sus cifras se midieron antes de corregir la fuga del 30 de agosto: sirven para comparar entre sí, no con la tabla anterior.

Precio absoluto frente a residuo. En las primeras iteraciones, ningún modelo en escala absoluta batía a la persistencia: MLP 20,9, LSTM 23,9 y Seq2Seq 27,2 €/MWh, frente a 17,1. Predecir la diferencia con el día anterior bajó el Seq2Seq a 15,1. Fue el cambio que separó no batir a la persistencia de batirla.

Técnicas del temario. Un Seq2Seq base y cinco variantes con lo que se usa en los módulos 12 y 14: estados del codificador pasados al decodificador, regularización L2, ruido gaussiano, normalización de capa y atención. La mejor se quedó en 13,19 €/MWh, frente a los 12,28 de la GRU.

Búsqueda de hiperparámetros. Hyperband (módulo 12.1) exploró entre 60 y 90 configuraciones, y la búsqueda manual se limitó a ocho: con un año de validación, probar decenas de combinaciones y quedarse con la mejor sobreajusta la validación. Ninguna cambió qué arquitectura era la mejor.

Fine-tuning y recencia. Rematar el entrenamiento con los días recientes, probando cuatro fechas de corte (entre ellas el 1 de abril de 2024, cuando empieza el archivo de previsiones de ECMWF), y dar más peso a lo reciente con una vida media de un año. Resultado: 13,05 y 13,04 €/MWh, ligeramente peor que el Seq2Seq de partida (12,86).

APARTADOS A Y B DE LA GUÍA

Qué aporta frente a un AutoML y a un trabajo de módulo

Un AutoML habría entrenado arquitecturas parecidas y devuelto la de menor error en validación. La diferencia está en siete decisiones que solo aparecen al examinar el problema, y cada una deja rastro en los resultados.

15,39 €/MWh Error en test del modelo con mejor MAE de validación (el Denso, con 12,79). Es el que elegiría el criterio por defecto.	12,13 €/MWh Error en test del ensemble por familias: 3,26 €/MWh menos. La persistencia marca 16,71.
---	---

Seleccionar por robustez, no por el mínimo de validación.

El orden de validación no anticipa el de test (correlación de rangos de -0,14). El ensemble por familias no apuesta por un ganador y es el mejor en ambos periodos.

Una frontera de información auditada.

Cada columna entra con la hora a la que se publica de verdad, medida contra las tablas de origen. El 30 de agosto se detectó que el codificador recibía la generación observada del propio día D, que a las 11:00 aún no existe; se corrigió y se reentrenó todo, aunque los números empeoraran. Una búsqueda automática habría preferido la versión con fuga.

La métrica del negocio junto a la estadística.

El MAE pesa igual las 24 horas, pero el margen de una batería depende de acertar el valle y el pico. Medir la captura mostró que ambos criterios eligen modelos distintos: la GRU por error y el Seq2Seq absoluto por captura.

Semillas antes que conclusiones.

Tres entrenamientos por familia, con media ± desviación. Las semillas del Denso difieren 1,58 €/MWh en test, más que la distancia entre la mejor familia y la quinta (0,99): con una sola ejecución, el ranking sería azar.

Un experimento controlado, no un catálogo.

Cada familia cambia una sola pieza respecto al Seq2Seq —celda, decodificador, objetivo, convolución, recurrencia o paradigma—, así que cada diferencia tiene causa. La matriz de variables se trató igual: cuatro candidatas comparadas en 36 entrenamientos pareados por semilla y arquitectura, y la núcleo gana en las 27 comparaciones (a la mínima por 3,07 €/MWh, a la completa por 2,25 y a la moderna por 1,76).

Errores encontrados al mirar los resultados.

La familia `lstm` construía exactamente el mismo modelo que `seq2seq` (259.681 parámetros y una correlación de 0,99947 entre sus predicciones) y duplicaba su voto. El boosting daba una desviación de 0,000 porque la semilla no tenía efecto. Y el ensemble anterior elegía miembros mirando el test y promediaba dieciséis modelos, diez de ellos el mismo codificador-decodificador. Ninguno de los tres lanza un error: solo se ven mirando.

Del temario al problema.

Los patrones de clase se adaptaron donde habrían sido errores: nada de capas bidireccionales en el decodificador, salida lineal con pérdida Huber en lugar de softmax y escaladores ajustados solo con entrenamiento. Además, cada modelo se exporta con su preprocesado —orden de columnas, escaladores y huella de la matriz—, porque un modelo cargado con las columnas cambiadas sigue prediciendo números plausibles y equivocados.

FUENTES

- Arquitecturas, entrenamiento y métricas: `scripts/entrenar_finales.py`
- Tensores, partición y frontera de información: `scripts/preparar_tensores.py`
- Resultados del 30/08/2026: `notebooks/06_modelos_finales.ipynb` → `data/gold/finales_nucleo/tabla_final.csv`, `por_semilla.csv` y `meta.json`
- Comparación de matrices: `notebooks/05_comparacion_matrices.ipynb` y `data/gold/rejilla_matrices.csv`
- Exploración: `modelos/RNN/modelo_rnn_v2_temario.ipynb` y `modelos/RNN/comparativa_modelos.csv`

No incluye los modelos que el resto del equipo entrenó fuera de estos scripts (lineales, SARIMA y boosting propios).